

Práctica 2 - Práctica de busca

Marcos Fernández Pichel

Curso 2026-2027 Grao en Intelixencia Artificial - USC

A **Recuperación da Información** (RI) é unha área de investigación que, dada unha consulta dun/dunha usuario/a, trata de atopar os documentos relevantes para ela. Trátase da ciencia que está detrás dos algoritmos dos motores de busca como Google. Como os/as usuarios/as escriben en linguaxe natural, é unha tarefa moi relacionada coas tecnoloxías da linguaxe.

En todo problema de busca, sempre imos ter un corpus de documentos (C), unha ou varias consultas (q) e un **índice invertido** (I). O índice invertido é a estrutura clave que permite emparellar consultas e documentos de maneira eficiente.

Ademais, en investigación e avaliación da RI tamén se empregan os chamados **xuízos de relevancia** (*relevance judgments* ou *grels*), que indican que documentos do corpus son realmente relevantes para cada consulta. Estes xuízos adoitan ser elaborados por persoas expertas ou anotadores/as e constitúen a “verdade” (*ground truth*) que permite avaliar a calidade dun sistema de recuperación mediante métricas como $NDCG@k$, $Precision@k$, $Recall@k$ ou *Mean Average Precision* ($MAP@k$).




Figure 1: Estructura de índice invertido

Nesta práctica compararemos representacións vectoriais clásicas e *embeddings* nunha tarefa de Recuperación da Información (RI).

1 Tarefas a realizar

1. O noso corpus (C) vai ser a colección CACM (<http://www.search-engines-book.com/collections/>), un corpus de artigos científicos. O corpus de documentos está en formato

HTML, polo que deberedes utilizar algunha librería de Python para eliminar as etiquetas HTML e indexar unicamente o texto plano. Por exemplo, podedes empregar BeautifulSoup (<https://www.crummy.com/software/BeautifulSoup/bs4/doc/>).

2. Unha vez cargada a colección, deberedes crear o voso primeiro índice. A primeira librería que utilizaremos será Whoosh (<https://whoosh.readthedocs.io/en/latest/intro.html>), que internamente representa os documentos como frecuencias de palabras.¹

Para crear o índice deberedes definir un esquema de campos para os documentos no que, como mínimo, se almacene o título como un campo separado (asumindo que o título de cada documento é sempre a primeira oración do texto) e outro campo `body` que conteña o texto completo do documento (incluíndo o título). Tamén será necesario gardar o nome do ficheiro (sen a extensión HTML) como un campo identificador independente.

3. Dado o ficheiro de consultas (*queries*) da colección CACM (só o ficheiro *processed queries*), trátase de realizar unha avaliación de tipo *batch* das mesmas, consistente en (de maneira iterativa):
 - (a) Ler a consulta do ficheiro e lanzala contra o índice.
 - (b) Recuperar os 10 primeiros resultados.
 - (c) Calcular, para eses 10 primeiros resultados, a **Precisión@10** e o **Reciprocal Rank (RR)** da busca. Para iso, é necesario coñecer cales son os documentos relevantes para cada consulta. Esta información atópase no ficheiro <http://www.search-engines-book.com/data/cacm.rel>, que contén os **xuízos de relevancia** (*relevance judgments*) do conxunto de consultas. En concreto, a primeira columna corresponde ao número da consulta, a terceira ao identificador do documento e a cuarta indica cun valor 1 os documentos relevantes para esa consulta. Recoméndase ler esta información ao comezo do programa para dispoñer dun método eficiente de acceso aos documentos relevantes de cada consulta.
 - (d) O programa deberá informar individualmente da Precisión@10 e do RR de cada consulta e, ao finalizar, mostrar o valor medio de ambas métricas, calculado sobre o conxunto completo de consultas do *benchmark*.
 - (e) Para estas buscas, empregaremos o modelo por defecto de Whoosh: BM25F.² Realízade os experimentos empregando as seguintes variantes de busca:
 - Busca unicamente sobre o campo `title` utilizando o modelo **BM25F**.
 - Busca unicamente sobre o campo `body` utilizando o modelo **BM25F**.
4. En segundo lugar, realizaremos buscas con representacións vectoriais con carga semántica (*embeddings*) dos documentos e das consultas. A librería de referencia para este propósito é FAISS: <https://github.com/facebookresearch/faiss>. Nesta parte, abonda con que indexedes unicamente o *body* dos documentos.³
 - (a) Adestrade un modelo de Word2Vec utilizando o corpus *C* e xerade o índice con FAISS. **Olo:** para obter os *embeddings* dos documentos, podedes representar cada documento como a media dos *embeddings* das súas palabras.

¹Se vos fixades, isto é moi semellante á matriz documento-termo que vimos no Tema 1.

²Verémolo en profundidade no Tema 5.

³Para unha colección de só uns poucos miles de documentos, `IndexFlatL2` é unha boa opción.

- (b) Repetide o proceso empregando agora os modelos predestrados *glove-twitter-25* e *word2vec-google-news-300*.
- (c) Finalmente, como introdución aos Transformers, xerade un índice FAISS utilizando modelos SBERT predestrados: https://www.sbert.net/docs/sentence_transformer/pretrained_models.html.
- (d) Para cada un dos anteriores, facede buscas mediante similaridade semántica para as mesmas consultas que no índice léxico e comparade os resultados.

2 Entregables

Deberedes entregar un **Python Notebook** coa vosa práctica, que deberá chamarse **apelidos_nome_entregable2.ipynb**. É fundamental que o Notebook sexa autoexplicativo en todos os pasos, combinando celas de texto con celas de código e mostrando explicitamente os resultados, sen necesidade de volver executar as celas.

Recordade, o único entregable **obligatorio** é o último, pero é preciso acadar unha nota **igual ou superior a 5** nas prácticas para superar a asignatura.

A parte da entrega do informe, esta práctica avaliarase cunha **defensa ante ao profesor**, avaliada con rúbrica, na sesión posterior á entrega.

3 Valoración e Data de Entrega

Esta práctica ten unha valoración de **1 punto** (sobre o total de 10 puntos da parte práctica da materia). A data límite de entrega é o **20 de outubro ás 23:59**.